

UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN

FACULTAD DE INGENIERÍA MECÁNICA Y ELÉCTRICA

SUBDIRECCIÓN ACADÉMICA



DETECCIÓN DE CANCER DE PIEL MEDIANTE
SEGMENTACIÓN SEMÁNTICA

POR

MARIO ALBERTO FLORES HERNÁNDEZ

COMO REQUISITO PARCIAL PARA OBTENER EL GRADO DE
LICENCIATURA EN INGENIERÍA EN MECATRÓNICA

FEBRERO 2021

UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN

FACULTAD DE INGENIERÍA MECÁNICA Y ELÉCTRICA

SUBDIRECCIÓN ACADÉMICA



DETECCIÓN DE CANCER DE PIEL MEDIANTE
SEGMENTACIÓN SEMÁNTICA

POR

MARIO ALBERTO FLORES HERNÁNDEZ

COMO REQUISITO PARCIAL PARA OBTENER EL GRADO DE
LICENCIATURA EN INGENIERÍA EN MECATRÓNICA

FEBRERO 2021



UNIVERSIDAD AUTÓNOMA DE NUEVO LEÓN
FACULTAD DE INGENIERÍA MECÁNICA Y ELÉCTRICA
SUBDIRECCIÓN ACADÉMICA

Los miembros del Comité de Tesis recomendamos que la Tesis «Detección de cancer de piel mediante segmentación semántica», realizada por el alumno Mario Alberto Flores Hernández, con número de matrícula 1719126, sea aceptada para su defensa como requisito parcial para obtener el grado de Licenciatura en Ingeniería en Mecatrónica.

El Comité de Tesis

Dra. Satu Elisa Schaeffer
Asesora

Dr. Romeo Sánchez Nigenda
Revisor

Dra. Sara Elena Garza Villarreal
Revisora

Vo. Bo.

Dr. Fernando Banda Muñoz
Subdirector Académico

San Nicolás de los Garza, Nuevo León, febrero 2021

ÍNDICE GENERAL

Índice de Figuras	VII
Índice de Cuadros	VIII
Notaciones	IX
Agradecimientos	X
Resumen	XI
1. Introducción	1
1.1. Hipótesis	3
1.2. Objetivos	3
1.3. Estructura de la Tesis	4
2. Antecedentes	6
2.1. Cáncer de Piel	6
2.1.1. Tipos de Cáncer de Piel	7
2.2. Redes Neuronales	8

ÍNDICE GENERAL	v
2.2.1. Imágenes como Datos	8
2.2.2. Modelo	9
2.2.3. Evaluación y Optimización	11
3. Estado del Arte	12
3.1. Trabajos Similares	13
3.2. Análisis Comparativo	16
3.3. Áreas de Oportunidad	17
4. Solución Propuesta	19
4.1. Metodología	20
4.1.1. Adquisición y Filtrado de Imágenes	20
4.1.2. Pre-Procesado de los Datos	20
4.1.3. Entrenamiento del Modelo	21
4.2. Implementación de la Solución	21
4.2.1. Descripción de los Datos	21
5. Diseño Experimental	22
6. Conclusiones	23
6.1. Discusión	23
6.2. Trabajo a Futuro	23
Glosario	24

ÍNDICE DE FIGURAS

1.1. Ilustración de las capas de la piel y sus apéndices [18].	1
1.2. Ejemplo de melanoma [11].	2
1.3. Ejemplo de segmentación: entrada y salida.	4
2.1. Comparación de dimensiones en imágenes en blanco y negro e imágenes a color.	9
2.2. Ejemplo de un perceptrón.	10

ÍNDICE DE CUADROS

3.1. Similitudes y diferencias entre los trabajos revisados, las características implementadas se representan con (✓), mientras que las no implementadas con (✕).	17
---	----

NOTACIONES

A continuación se resumen las notaciones usadas a lo largo de este trabajo de tesis, incluyendo el símbolo, significado y equivalente en el idioma inglés.

Símbolo	Definición	Equivalente al inglés
x	dato de entrada	<i>input</i>
y	dato de salida	<i>output</i>
\hat{y}	salida estimada	<i>estimated output</i>
d	dimensión de entrada	<i>input dimension</i>
d_o	dimensión de salida	<i>output dimension</i>
n_s	número de muestras	<i>samples</i>
e_i	entrada del modelo	<i>node input</i>
p_i	peso sináptico	<i>synaptic weight</i>
ϕ	función de activación	<i>activation</i>

AGRADECIMIENTOS

Quiero agradecer primeramente a mi madre Patricia Hernández Romero por siempre representar un ejemplo de esfuerzo y superación en cada uno de los obstáculos que se han presentado.

A mi padre Mario Alberto Flores Rosales (†), quien me enseñó las virtudes del trabajo y la disciplina.

A la Dra. Satu Elisa Schaeffer por la asesoría, paciencia y consejos otorgados durante el desarrollo de este trabajo.

Al Dr. Romeo Sánchez Nigenda y a la Dra. Sara Elena Garza Villarreal por el tiempo y comentarios otorgados para mejorar este trabajo.

A mis compañeros de la FIME y del ITESM quienes me han otorgado su tiempo para enriquecer y ampliar mis conocimientos y que además de eso, me han servido como modelos a seguir y ejemplos de superación.

RESUMEN

Mario Alberto Flores Hernández.

Candidato para obtener el grado de Licenciatura en Ingeniería en Mecatrónica.

Universidad Autónoma de Nuevo León.

Facultad de Ingeniería Mecánica y Eléctrica.

Título del estudio: DETECCIÓN DE CANCER DE PIEL MEDIANTE SEGMENTACIÓN SEMÁNTICA.

Número de páginas: 28.

OBJETIVOS Y MÉTODO DE ESTUDIO: Desarrollar una herramienta de asistencia para la detección de cáncer de piel utilizando las técnicas mas actuales de visión computacional e inteligencia artificial, se pretende desarrollar mediante *software* y tecnicas de *segmentación semántica* una aplicación que permita introducir una imagen y como resultado obtener un mapa de características segmentado en una o más categorías.

CONTRIBUCIONES Y CONCLUSIONES: La principal contribución de este trabajo de tesis está dirigido al área de *hospital 4.0*, ya que el método planteado para la detección del cáncer en la piel involucra el uso de las tecnologías desarrolladas mediante inteligencia artificial. Esto beneficia especialmente al proceso el paciente puede obtener su diagnóstico. [Pend: Agregar mas información.]

Firma de la asesora: _____
Dra. Satu Elisa Schaeffer

CAPÍTULO 1

INTRODUCCIÓN

La piel es considerada el órgano más grande del cuerpo humano; está compuesta por tres capas: *epidermis*, *dermis* e *hipodermis* (figura 1.1). La principal función de la piel es proteger al cuerpo de las hostilidades del medio ambiente como la radiación solar y los factores externos como las bacterias, sin embargo también cumple otras funciones importantes aparte de proteger los órganos y los tejidos internos, tales otras funciones son regular nuestra temperatura corporal, registrar sensaciones de presión, frío, calor y es una interfaz para poder sentir e interactuar con lo que tenemos a nuestro alrededor.




FIGURA 1.1: Ilustración de las capas de la piel y sus apéndices [18].

Sin embargo, debido a la exposición continua a las radiaciones de la luz es común desarrollar enfermedades en la piel que afectan la forma en que las células de la piel se reproducen, causando graves daños en el tejido celular y en algunos casos resultando letal. Estas anomalías en la piel se denominan como *cáncer de piel*, y se clasifican de la siguiente forma: cáncer de células basales, cáncer de células escamosas y melanomas [12].



FIGURA 1.2: Ejemplo de melanoma [11].

Su detección temprana es imprescindible para reducir las probabilidades de fallecimiento. Por lo tanto es necesario seguir desarrollando tecnologías que faciliten la detección de este tipo de padecimientos de forma rápida y sencilla; y que vaya enfocada en aumentar la accesibilidad a dichos diagnósticos y de esta forma reducir la tasa de mortalidad por este padecimiento.

En los últimos años se han logrado muchos avances en cuanto al desarrollo de software inteligente lo cuál ha permitido un mayor acceso a diferentes servicios, una de las tecnologías que han adquirido mayor importancia es la *red neuronal*, se trata de una tecnología que tiene la capacidad de *aprender* mediante el uso de datos históricos y mediante funciones de optimización crear un modelo matemático capaz de predecir, clasificar o recrear datos futuros o desconocidos. Algunos de los sectores que han comenzado a adoptar esta tecnología son: el sector automotriz (piloto automático), el sector de manufactura (optimización de procesos), el sector de entretenimiento (recomendaciones personalizadas), el sector médico (diagnóstico de imágenes).

1.1 HIPÓTESIS

Es posible clasificar los píxeles en distintas categorías dentro de una imagen gracias a los avances actuales de inteligencia artificial y la técnica de segmentación. Mediante la técnica de *segmentación semántica* es posible crear un reconocedor visual que no solo detecte la presencia y ubicación del elemento a reconocer, sino que, también obtenga otros datos descriptivos del elemento como el tamaño, forma y región que abarca dentro de la imagen.

1.2 OBJETIVOS

Primero en *objetivo general* se habla de manera conceptual la problemática a resolver tales como cuales son las situaciones en las que podemos optimizar la resolución de un problema mediante el uso de la red neuronal, posteriormente en los *objetivos específicos* se describe de forma puntual los pasos a realizar en el presente trabajo de tesis para llegar al resultado deseado.

El *objetivo general* de este trabajo de tesis es la creación de una aplicación con la capacidad de reconocer y segmentar melanoma en la piel de forma automatizada, con el motivo de asistir a los médicos dedicados a esta labor a optimizar y extender la detección temprana, consiguiendo así una reducción en su mortalidad.

El *objetivo específico*, es el implementar un modelo de red neuronal cuya entrada sean imágenes que pueden o no contener la presencia de alguno de los tipos de cáncer de piel comunes, y como salida del modelo se obtenga un mapa de características donde de haber presencia de el cáncer este se distinga mediante una región colorada en el espacio que abarca. El modelo debe cumplir con las siguientes características:

- El modelo debe ser capaz de trabajar con imágenes a color o en blanco y negro.
- El modelo debe contar con una función capaz de evaluar la precisión.

- El modelo debe contar con un algoritmo capaz de optimizar la precisión.
- El modelo debe ser capaz de segmentar correctamente imágenes no usadas en los datos de entrenamiento.




FIGURA 1.3: Ejemplo de segmentación: entrada y salida.

En la figura 1.3a se observa como la imagen entrante presenta un caso de melanoma, mientras que la figura 1.3b se puede observar la misma imagen después de pasar por una secuencia de transformaciones, esto se denomina *segmentación semántica* y se refiere a la acción de separar y clasificar en una o más categorías los objetos detectables en una imagen.

1.3 ESTRUCTURA DE LA TESIS

A continuación se da una breve explicación sobre el orden en el que se presentan los capítulos de este trabajo de tesis, así como una breve descripción de su contenido.

En el capítulo 2 se habla sobre los antecedentes relacionados al presente trabajo de tesis, primero se empieza definiendo la naturaleza del problema con el que se pretende tratar, después algunos conceptos clave que serán necesarios para la comprensión de la implementación propuesta tales como las dimensiones de los datos y los algoritmos de evaluación y optimización.

En el capítulo 3 se recopilan trabajos relacionados al método o problemática en cuestión, se estudia las características de dichos trabajos y se busca un punto de convergencia entre estos y el presente trabajo de tesis con el fin de comparar las áreas de oportunidad.

En el capítulo 4 se define el proceso de transformación de los datos del sistema propuesto en este trabajo de tesis, desde las características de los datos a la entrada.

El capítulo 5 describe a profundidad la implementación de la propuesta, desde la descripción de los datos utilizados para el entrenamiento del modelo y la verificación de este, la arquitectura específica utilizada

Finalmente, en el capítulo 6 se exponen los resultados obtenidos de la implementación del producto científico en el capítulo anterior, así como un análisis y conclusión final sobre los valores obtenidos en precision y tiempo de entrenamiento.

CAPÍTULO 2

ANTECEDENTES

En este capítulo se introduce de forma teórica conceptos relacionados con el trabajo propuesto, primero se define que es el *cáncer de piel*, cuales son los factores que influyen en el desarrollo de este padecimiento, los tipos de cáncer y las diferencias entre estos. Después algunos conceptos relacionados con las redes neuronales necesarios para un entendimiento sólido del *aprendizaje profundo*, tales como los elementos clave que conforman a la red neuronal, la manera en la que esta evalúa su precisión, y el algoritmo de optimización.

2.1 CÁNCER DE PIEL

El *cáncer de piel* es una enfermedad que suele relacionarse con la aparición de lunares o manchas que no se encontraban previamente, se pueden manifestar como manchas oscuras o rojizas, bultos y/o escamas en la superficie de la piel y afecta a todos los tonos de la piel por igual. Esta enfermedad se desarrolla principalmente en partes del cuerpo expuestas al sol, sin embargo también se puede desarrollar en partes que no suelen exponerse. Algunos factores como la exposición a los rayos ultravioletas (UV), el uso de sustancias como el tabaco o el envejecimiento son factores correlacionados con la aparición del *cáncer de piel*, existen dos factores de envejecimiento y se dividen en dos grupos: *intrínsecos* y *extrínsecos*.

Los factores *intrínsecos* son aquellos que suceden de forma interna en la piel, un ejemplo de esto es el envejecimiento cronológico, el cual es un proceso natural que consiste en degradación del colágeno, la elastina y el adelgazamiento de la epidermis debido al envejecimiento celular al paso de los años y de el efecto de algunas hormonas.

Los factores *extrínsecos* son aquellos que suceden de forma agena al organismo, como es el caso del *foto-envejecimiento* el cual sucede cuando nos encontramos expuestos a los rayos ultravioletas (UV). Este factor de envejecimiento genera lesiones en las cadenas de ácido desoxirribonucleico (ADN) debido a la oxidación y afecta la regeneración de células, al sistema inmune y a la forma en la que se regula la pigmentación [14].

2.1.1 TIPOS DE CÁNCER DE PIEL

El cáncer de piel es un padecimiento que se puede manifestar en una gran variedad de formas distintas, algunas de estas formas pueden representar un enorme riesgo para la salud de quien la padece mientras que otras pueden permanecer mucho tiempo sin afectar la calidad de vida del paciente; se clasifican principalmente en dos tipos: *benigno* y *maligno*.

Los tumores del tipo *benignos* no suelen ser considerados cáncer como tal, ya que tienen un crecimiento lento y no suelen extenderse a otras partes del cuerpo, por otro lado los tumores *malignos*, si representan un riesgo mayor ya que crecen rápidamente y suelen hacer *metástasis*, osea que migran a otras partes del cuerpo.

2.2 REDES NEURONALES

Hasta hace algunos años el desarrollo de aplicaciones de software solía realizarse de forma robústa, por ejemplo, si deseáramos desarrollar una aplicación de reconocimiento de imágenes faciales de la forma tradicional, sería necesario un grupo de expertos en dicho rubro para que definan una secuencia de transformaciones específicas para lograr esa función, donde la variabilidad de las imágenes que dicho sistema permitiría depende específicamente de la complejidad del mismo, sin embargo mediante las redes neuronales es posible resolver el mismo problema con la ventaja de que la variabilidad de imágenes que pueden ser reconocidas por el sistema, depende de los datos utilizados para el entrenamiento, el model de una red neuronal *aprende* de los datos proporcionados y crea un modelo capaz de clasificar, predecir o reconstruir datos conocidos y desconocidos. Algunos de los puntos clave que conforman un sistema basado en redes neuronales son:

- Datos: Se debe determinar la naturaleza y la dimensión de los datos que entrarán al modelo.
- Modelo: Se debe crear un sistema que transforme los datos de entrada, en la salida deseada.
- Evaluación: El modelo debe tener la capacidad de evaluar su precisión.
- Optimización: El modelo debe contar con un algoritmo que optimice la precisión.

2.2.1 IMÁGENES COMO DATOS

Las imágenes se pueden definir como una matriz de $m \times n \times 1$ píxeles en el caso de las imágenes de un solo canal (blanco y negro) y en el caso de imágenes a

color es de $m \times n \times k$, donde k es igual al numero de canales de color que tenga la imagen, siendo tres en el caso de imágenes RGB¹, es importante definir si las imágenes ingresarán al modelo a color o en blanco y negro debido a que esto define el numero de nodos de entrada de este, ya que para cada pixel debe corresponder un nodo de entrada y en el caso de imágenes a color también deberá tener un número de capas de nodos de entrada igual al número de canales que tenga la imagen.

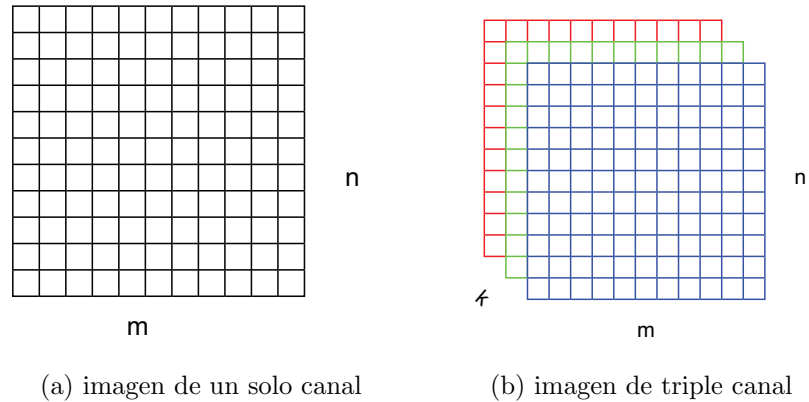


FIGURA 2.1: Comparación de dimensiones en imágenes en blanco y negro e imágenes a color.

2.2.2 MODELO

Un *modelo* se puede definir como el bloque intermedio entre los datos de entrada (*input*) y los datos de salida (*output*), es el sistema encargado de transformar los datos de entrada en la salida deseada y consta de los siguientes componentes:

La unidad principal que compone el modelo de la red neuronal es el perceptrón, denominado *nodo* en esta literatura. Se trata de una analogía matemática basada en el comportamiento de la neurona biológica, el nodo recibe n entradas, las cuales son multiplicadas por el peso p , se suma el producto de las entradas por sus pesos $e \times p$ y finalmente se multiplica por la función de activación ϕ .

¹RGB: Se refiere a los tres canales de color rojo, verde y azul, por sus siglas en inglés (*red*, *green*, *blue*).

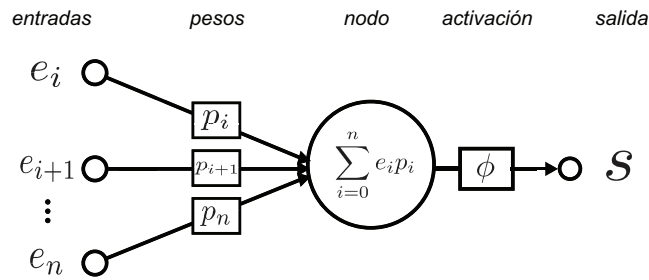


FIGURA 2.2: Ejemplo de un perceptrón.

Partiendo de lo anterior, creando arreglos con estos nodos podemos formar estructuras denominadas *redes neuronales*, las cuales cuentan con los siguientes elementos estructurales:

- **Capa de nodos de entrada (*input nodes*):** Se trata de la primera capa del modelo, en el caso de imágenes a cada pixel le corresponde un nodo de entrada. Estos nodos deben tener las mismas dimensiones que las imágenes de entrada.
- **Capa de nodos ocultos (*hidden nodes*):** Las dimensiones de estos nodos pueden ser diferentes a los de entrada y tener varias capas ocultas, sin embargo esto puede afectar la complejidad y precisión del modelo.
- **Capa de nodos de salida (*output nodes*):** Esta es la capa de salida del modelo, las dimensiones de la capa de salida determinan las dimensiones del dato resultante.
- **Función de activación (*activation*):** Se trata de una función dentro de cada nodo que interactúa con el valor entrante y se multiplica por el peso.
- **Pesos (*weights*):** Se trata de un valor entre el nodo de la capa actual y el nodo siguiente inicializado de forma aleatoria y después ajustado por un algoritmo para aproximar la salida al valor real.
- **Sesgo (*bias*):** Se trata de un valor constante que se suma al resultado de la función de activación y el peso, de esta forma se puede ajustar que tan fácil o difícil es activar un nodo.

2.2.3 EVALUACIÓN Y OPTIMIZACIÓN

Para realizar el proceso de *aprendizaje* del modelo, primero se debe evaluar cuál es el estado actual de las predicciones. Para esto es necesario evaluar que distancia existe entre el valor predicho y el valor real, esto se puede lograr mediante una *función de pérdida* que se encargue de determinar que tanta diferencia (*loss*) existe en las estimaciones del modelo con los pesos actuales.

Un ejemplo de la función de pérdida es el de la función logarítmica del costo (*log-likelihood*), como se muestra a continuación en donde:

$$l(\mathbf{y}, \hat{\mathbf{y}}) = - \sum_{j=1}^q y_j \log \hat{y}_j$$

- q representa el número de clases entre las debe cuales predecir.
- y_j representa valor real.
- \hat{y}_j representa valor estimado por el modelo.
- j representa la posición en el indizado de las clases.

Ya que se tiene calculada la pérdida del modelo en su configuración actual, es necesario actualizar el valor de todos los pesos dentro del modelo para poder acercarnos al valor real. Aquí es donde se requiere un algoritmo que primero determine si el peso de cada nodo debe aumentar o disminuir, y después de determinar la dirección realizar un ajuste antes de volver a evaluar el modelo.

Para esto existe el algoritmo de *gradiente descendiente*, comienza en un punto inicial y repetidamente da un paso hacia la dirección opuesta del gradiente en cada punto y así minimizar el *costo*. A continuación se representa la forma del algoritmo:

[Pend: Arreglar algorithmicx]

CAPÍTULO 3

ESTADO DEL ARTE

En este capítulo se estudia las literaturas relacionadas con el presente trabajo de tesis con el objetivo de hacer una comparativa entre distintos métodos para resolver el mismo problema, o implementaciones similares para resolver problemas distintos.

En la primera sección, *trabajos similares*, se recopilan trabajos con características relacionadas al presente trabajo de tesis, ya sea relacionados con el método o con el problema que se pretende resolver, se describe el tema que abarcan y los puntos que lo relacionan con el trabajo aquí presente.

En la segunda sección, *análisis comparativo*, se comparan las distintas características de los trabajos revisados, de esta forma podemos determinar las principales diferencias así como las ventajas y desventajas de cada trabajo. Así mismo se recopilarán todas estas diferencias en una tabla para visualizar mejor estas características.

Finalmente en las *áreas de oportunidad*, se realiza una conclusión acerca de los resultados en la tabla comparativa.

3.1 TRABAJOS SIMILARES

A continuación se mencionan los trabajos revisados en los que se puede obtener un punto de convergencia ya sea en los métodos similares utilizados para resolver problemas diferentes o en su defecto métodos distintos para resolver problemas similares.

Badrinarayanan *et al.* [1] en este trabajo se habla sobre la arquitectura denominada *SegNet* utilizada principalmente para la conducción autónoma y la detección de peatones, se describe como una arquitectura convolucional, con la característica de que es una jerarquía de codificador-decodificador donde a cada codificación (*encoding*) corresponde una capa de agrupación de máximos (*max pooling*) y un decodificador. Inspirado principalmente en la arquitectura *VGG16*, con la diferencia de que el componente clave en esta arquitectura es el uso de convoluciones en lugar de la capa completamente conectada de nodos (*fully-connected-layer*) a la salida.

Ronneberger *et al.* [15] proponen uno de los primeros modelos de la redes neuronales convolucionales denominada *U-net* dirigida al análisis de imágenes del área médica. Este trabajo consiste en una arquitectura con dos trayectorias: la trayectoria de contracción de la imagen y la trayectoria de expansión. En la trayectoria de contracción de la imagen se aplica una secuencia de convoluciones de dimensión 3×3 con solapado, seguido de una función de activación de rectificación lineal unitaria (*ReLU*) y posteriormente una operación de agrupación de máximos (*max pooling*) para la compresión de la imagen (*downsampling*). Por otro lado, la trayectoria de expansión consiste de el escalado de la imagen (*upsampling*), en cada paso se aplica una capa de convolución de 2×2 a la cuál se concatena una imagen recortada del mapa de características de la trayectoria de contracción y dos convoluciones de 3×3 seguidos de una activación ReLu cada una. En total la arquitectura tiene 23 convoluciones (U-net).

Chen *et al.* [3] en este trabajo hablan de la arquitectura denominada *Deep Lab*, la cual propone un acercamiento distinto a la parte de la reconstrucción en las capas finales del modelo. Al igual que otras arquitecturas cuenta con capas de convolución, agrupación de máximos y activación de rectificación lineal unitaria, sin embargo, el componente clave aquí es la denominada convolución de hoyos (*atrous convolution*), la cual es una modificación al filtro de convolución basado en la transformada de *Wavelet* para el escalado del mapa de características (*upsampling*). De esta forma se obtiene una alternativa al uso de capas de deconvolución y así se aumenta la resolución del mapa de características a la salida del modelo sin aumentar el tiempo de computación o la cantidad de parámetros.

Teichmann *et al.* [17] reducen la carga computacional en los modelos de redes neuronales convolucionales mediante la unificación de las tres tareas principales de estas: clasificación, detección y segmentación. Denominada como multi-red neuronal (*multinet*) se trata de una arquitectura tipo codificador-decodificador en donde el decodificador esta compuesto de tres ramas las cuales corresponden a las tareas de clasificación, detección y segmentación por lo que se realizan las tres tareas de forma simultanea partiendo de la misma entrada (*multi-tasking*) y usando la salida de cada una de las ramas para el ajuste fino de los parámetros del modelo (*fine-tuning*).

Kroner *et al.* [9] hablan sobre un modelo de codificación-decodificación contextual basado en el proceso en el que los humanos obtenemos la información espacial de los escenarios visuales complejos, mediante un mapa topográfico de las salientes. Se basa en más en el proceso biológico con el que se obtiene la información espacial que en los métodos matemáticos para calcularla, dicho lo anterior, los principales componentes para determinar una saliente son color, la intensidad y la orientación.

Kadampur y Al Riyae [8] proponen el uso de los servicios de nube en conjunto con las redes neuronales profundas y el diseño de modelos utilizando modelos pre-entrenados. Para esto utilizan la herramienta de *deep learning studio (DLS)*, la cual es un software que permite el uso de tarjetas gráficas (*GPU*) localizadas en

la nube o localmente, y también permite el uso de múltiples tarjetas de forma simultánea (*multi-GPU*), la arquitectura usada para la detección de cáncer de piel en este trabajo es de una red neuronal profunda de clasificación, por lo que el modelo se codifica mediante convoluciones y se decodifica mediante capas de aplanamiento (*flatten layer*) para posteriormente entrar a una capa de nodos completamente conectada (*fully-connected-layer*) y obtener dos posibles resultados: es cáncer o no es cáncer.

Zhou *et al.* [21] hablan sobre el uso del aprendizaje de máquina (*machine learning*) y las redes neuronales para la predicción teórica de nano-materiales. Para conseguir esto, es necesario determinar el número de capas y la heterogeneidad del material para posteriormente entender fenómenos visuales como el parpadeo y la emisión cuántica, concluyendo que las intensidades RGB están correlacionadas al número de capas en el material del grafeno.

Luc *et al.* [10] proponen una alternativa al proceso de decodificación. Normalmente en las tareas de segmentación es necesaria la parte de codificación para realizar las predicciones a grado pixel y la decodificación para reconstruir la imagen con las categorías segmentadas. Este trabajo propone el uso de una red generativa adversaria (*GAN*), para utilizarse como decodificador, de esta manera se obtiene un mapa de etiquetas (*map layer*) con una mayor resolución.

Jain *et al.* [7] desarrollan una herramienta de procesamiento de imágenes médicas relacionadas al melanoma, basándose en sus características físicas como: asimetría, color, bordes y diámetro. Se basa en la técnica de segmentación de imágenes mediante el uso de filtros de contraste, detección de ejes, etc. A diferencia de los otros trabajos mencionados, este no consiste del uso de redes neuronales sino de filtrados de imagen mediante convoluciones para obtener la máscara.

3.2 ANÁLISIS COMPARATIVO

En esta sección se evalúan los trabajos revisados con el trabajo propuesto en este trabajo de tesis, para esto se define una serie de características que servirán como puntos de referencia entre el trabajo propuesto y los trabajos relacionados, dichas características son las siguientes:

Modelo. Tipo de arquitectura del modelo.

Clasificación. El sistema puede clasificar entre distintas categorías.

Segmentación. El sistema puede segmentar las imágenes.

Supervisado. El sistema requiere de datos de datos de entrenamiento.

Pre-entrenamiento. El sistema puede inicializarse con pesos pre-entrenados como alternativa a la inicialización con pesos aleatorios.

Evaluación. El sistema cuenta con una función de evaluación y un algoritmo de optimización.

Salida. Características de los datos obtenidos en la salida del modelo.

CUADRO 3.1: Similitudes y diferencias entre los trabajos revisados, las características

implementadas se representan con (✓), mientras que las no implementadas con (✗).

Trabajo	Modelo	Clasificación	Segmentación	Supervisado	Pre-entrenamiento	Evaluación	Salida
Badrinarayanan <i>et al.</i> [1]	SegNet	✓	✓	✓	✓	✓	label map
Ronneberger <i>et al.</i> [15]	U-net	✓	✓	✓	✗	✓	label map
Chen <i>et al.</i> [3]	DeepLab	✓	✓	✓	✗	✓	label map
Teichmann <i>et al.</i> [17]	MultiNet	✓	✓	✓	✗	✓	label map
Kroner <i>et al.</i> [9]	VGG16	✓	✓	✓	✓	✓	heat map
Kadampur y Al Riyae [8]	CNN	✓	✗	✓	✗	✓	label map
Zhou <i>et al.</i> [21]	ML / SVM	✓	✗	✓	✗	✓	label
Luc <i>et al.</i> [10]	CNN/GAN	✓	✓	✓	✓	✓	label map
Jain <i>et al.</i> [7]	A.B.C.D	✗	✓	✗	✗	✗	label
Propuesta de tesis	FPN	✓	✓	✓	✓	✓	label map

3.3 ÁREAS DE OPORTUNIDAD

En esta sección se señalan las características de los trabajos mencionados en la sección anterior y se compara con las características del método propuesto en este trabajo de tesis para obtener una comparativa sobre las áreas de oportunidad.

Para las tareas de segmentación es fundamental contar con un codificador y un decodificador eficientes, sin embargo aún más importante es tener la capacidad de evaluarse así mismo y optimizarse, a diferencia de algunas técnicas más robustas

de diseño, las redes neuronales convolucionales permiten esas funcionalidades.

Otro aspecto importante a considerar es la capacidad del uso de pesos pre-entrenados a la hora de entrenar utilizando nuestros datos, ya que incluso cuando los pesos pre-entrenados fueron obtenidos mediante bases de datos no necesariamente relacionadas con el o los objetos que nosotros queremos detectar, pero con similitudes físicas, en teoría ofrece un mejor desempeño y reduce el tiempo de entrenamiento ya que de lo contrario, se tendría que inicializar el modelo con pesos distribuidos de forma aleatoria, por lo que la precisión inicial del modelo sería cercana al cero por ciento. En este trabajo de tesis, el modelo propuesto cuenta con la capacidad de utilizar pesos pre-entrenados, el reto está en seleccionar un conjunto de pesos que mejoren la precisión en el caso de imágenes médicas, ya que si los pesos utilizados fueron obtenidos con imágenes que difieren mucho de las imágenes que se utilizadas en el presente trabajo, podría verse comprometida la precisión o el tiempo de entrenamiento.

CAPÍTULO 4

SOLUCIÓN PROPUESTA

El objetivo de este trabajo de tesis es realizar la segmentación semántica de los tejidos sanos y los tejidos con cáncer de piel mediante el uso de las redes neuronales profundas, para demostrar ésto fue desarrollada una aplicación de software que permite configurar distintas arquitecturas de redes neuronales y utilizar una base de datos con imágenes de casos clinicos de melanoma para el entrenamiento de ésta.

En este capítulo se describe de forma estructural el software desarrollado, las entradas, salidas y las distintas fases que lo componen; así mismo se describe el proceso de la implementación tomando en cuenta el ambiente en el que fue desarrollado y las pruebas realizadas para validar su funcionamiento. El producto que se desea obtener con este sistema es el de un *mapa de características* también denominado *mapa segmentado*, que consiste en una reconstrucción anotada de la imagen de entrada, donde se indica la categoría asignada a cada región. Para esto es necesario pasar por varias etapas: cargado de datos, secuencia de transformaciones, codificación, reconstrucción y salida.

4.1 METODOLOGÍA

En esta sección se explican los procesos llevados a cabo para la obtención del mapa segmentado, a continuación se muestra un diagrama de flujo el cual resume la secuencia de acciones a ejecutar, comenzando con la obtención de las imágenes, la extracción de las características y la reconstrucción de la imagen.

[Pend: Crear diagrama de vectores.]

4.1.1 ADQUISICIÓN Y FILTRADO DE IMÁGENES

Para entrenar el modelo primero es necesario contar con una base de datos de la cual extraer las imágenes que se utilizarán, las imágenes de entrenamiento para segmentación deben estar divididas en dos secciones: imagen real, máscara anotada. La imagen real es aquella que en el post-entrenamiento recibirá como entrada, mientras que la máscara anotada es el resultado que se espera obtener de dicha entrada.

4.1.2 PRE-PROCESADO DE LOS DATOS

Las imágenes por sí mismas pueden crear un modelo de segmentación eficiente, sin embargo para que puedan ingresar al modelo es necesario que tenga una forma específica. En el caso del modelo de segmentación es necesario que la matriz de píxeles se encuentre en forma de *tensor*, esto se puede hacer mediante el pre-procesado.

[Pend: Diagrama de pre-procesamiento de imagen a tensor.]

4.1.3 ENTRENAMIENTO DEL MODELO

Antes de poder realizar segmentaciones con el sistema desarrollado, es necesario entrenarlo para poder segmentar el objeto deseado, esto es denominado *aprendizaje supervisado* y se refiere a que el modelo hará predicciones basandose únicamente de los datos que le fueron provistos.

4.2 IMPLEMENTACIÓN DE LA SOLUCIÓN

4.2.1 DESCRIPCIÓN DE LOS DATOS

Las imágenes utilizadas para el entrenamiento de este modelo fueron proporcionadas por la asociación internacional de recopilación de imágenes de la piel (*ISIC*¹).

¹ISIC: International Skin Imaging Collaboration.

CAPÍTULO 5

DISEÑO EXPERIMENTAL

CAPÍTULO 6

CONCLUSIONES

6.1 DISCUSIÓN

6.2 TRABAJO A FUTURO

GLOSARIO

dermis

Se trata de la capa intermedia de la piel, es más gruesa que la epidermis y está conformada de folículos pilosos, glándulas sudoríparas, vasos sanguíneos y nervios los cuales están sostenidos por colágeno. 1

epidermis

Se trata de la capa mas superficial de la piel, es también la mas delgada y está conformada en su mayoría por células llamadas queratinocitos o células escamosas, células basales y melanocitos. 1

hipodermis

Se trata de la capa mas profunda de la piel, la principal función de esta capa es regular la temperatura y amortiguar los golpes externos para proteger a los órganos. 1

red neuronal

Modelo matemático optimizado mediante funciones de cálculo para dar una salida deseada en base a una entrada. 2

segmentación semántica

Algoritmo de la inteligencia artificial que asocia una categoría o etiqueta a cada píxel de una imagen. XI, 3

BIBLIOGRAFÍA

- [1] BADRINARAYANAN, V., A. KENDALL y R. CIPOLLA (2015), «SegNet: A Deep Convolutional Encoder-Decoder Architecture for Image Segmentation», *CoRR*, **abs/1511.00561**, 1511.00561[cs.CV], URL <http://arxiv.org/abs/1511.00561>.
- [2] BONI, R., C. SCHUSTER, B. NEHRHOFF y G. BURG (2002), «Epidemiology of skin cancer», *Neuroendocrinology Letters*, **23**, págs. 48–51.
- [3] CHEN, L., G. PAPANDREOU, I. KOKKINOS, K. MURPHY y A. L. YUILLÉ (2016), «DeepLab: Semantic Image Segmentation with Deep Convolutional Nets, Atrous Convolution, and Fully Connected CRFs», *CoRR*, **abs/1606.00915**, 1606.00915[cs.CV], URL <http://arxiv.org/abs/1606.00915>.
- [4] CODELLA, N. C. F., V. ROTEMBERG, P. TSCHANDL, M. E. CELEBI, S. W. DUSZA, D. GUTMAN, B. HELBA, A. KALLOO, K. LIOPYRIS, M. A. MARCHETTI, H. KITTLER y A. HALPERN (2019), «Skin Lesion Analysis Toward Melanoma Detection 2018: A Challenge Hosted by the International Skin Imaging Collaboration (ISIC)», *CoRR*, **abs/1902.03368**, 1902.03368[cs.CV], URL <http://arxiv.org/abs/1902.03368>.
- [5] CODELLA, N. C. F., V. ROTEMBERG, P. TSCHANDL, M. E. CELEBI, S. W. DUSZA, D. GUTMAN, B. HELBA, A. KALLOO, K. LIOPYRIS, M. A. MARCHETTI, H. KITTLER y A. HALPERN (2019), «Skin Lesion Analysis Toward Melanoma Detection 2018: A Challenge Hosted by the International Skin

- Imaging Collaboration (ISIC)», *CoRR*, **abs/1902.03368**, 1902.03368, URL <http://arxiv.org/abs/1902.03368>.
- [6] GJ., T. y G. SR. (1993), «PRINCIPLES OF ANATOMY AND PHYSIOLOGY», URL <https://www.clinimed.co.uk/wound-care/wound-essentials/structure-and-function-of-the-skin#:~:text=The%20skin%20consists%20of%20two,the%20functions%20of%20the%20skin>.
- [7] JAIN, S., V. JAGTAP y N. PISE (2015), «Computer Aided Melanoma Skin Cancer Detection Using Image Processing», *Procedia Computer Science*, **48**, págs. 735 – 740, international Conference on Computer, Communication and Convergence (ICCC 2015), URL <http://www.sciencedirect.com/science/article/pii/S1877050915007188>.
- [8] KADAMPUR, M. A. y S. AL RIYAE (2020), «Skin cancer detection: Applying a deep learning based model driven architecture in the cloud for classifying dermal cell images», *Informatics in Medicine Unlocked*, **18**, pág. 100282, URL <http://www.sciencedirect.com/science/article/pii/S2352914819302047>.
- [9] KRONER, A., M. SENDEN, K. DRIESSENS y R. GOEBEL (2020), «Contextual encoder–decoder network for visual saliency prediction», *Neural Networks*, **129**, págs. 261 – 270, URL <http://www.sciencedirect.com/science/article/pii/S0893608020301660>.
- [10] LUC, P., C. COUPRIE, S. CHINTALA y J. VERBEEK (2016), «Semantic Segmentation using Adversarial Networks», *CoRR*, **abs/1611.08408**, 1611.08408, URL <http://arxiv.org/abs/1611.08408>.
- [11] MARAZZI, D. P. (2012), «Science Photo Library», URL https://ichef.bbci.co.uk/news/660/media/images/77303000/jpg/_77303278_skin_cancer-spl-1.jpg.
- [12] MEDICAL, T. A. C. S. y EDITORIAL CONTENT TEAM (2019), «What Are Basal and Squamous Cell Skin Cancers?», URL <https://www.clinimed.co.uk/wound-care/wound-essentials/structure-and-function-of-the-skin#:~:text=The%20skin%20consists%20of%20two,the%20functions%20of%20the%20skin>.

- [//www.cancer.org/cancer/basal-and-squamous-cell-skin-cancer/about/what-is-basal-and-squamous-cell.html](http://www.cancer.org/cancer/basal-and-squamous-cell-skin-cancer/about/what-is-basal-and-squamous-cell.html).
- [13] OF ARTIFICIAL INTELLIGENCE, B. A. (2020), «Suggested Notation for Machine Learning», <https://github.com/Mayuyu/suggested-notation-for-machine-learning>.
- [14] RITTIE, L. y G. J. FISHER (2015), «Natural and Sun-Induced Aging of Human Skin», *Cold Spring Harb Perspect Med*, doi: 10.1101/cshperspect.a015370.
- [15] RONNEBERGER, O., P. FISCHER y T. BROX (2015), «U-Net: Convolutional Networks for Biomedical Image Segmentation», *CoRR*, **abs/1505.04597**, 1505.04597[cs.CV], URL <http://arxiv.org/abs/1505.04597>.
- [16] SHELHAMER, E., J. LONG y T. DARRELL (2016), «Fully Convolutional Networks for Semantic Segmentation», *CoRR*, **abs/1605.06211**[cs.CV], 1605.06211[cs.CV], URL <http://arxiv.org/abs/1605.06211>.
- [17] TEICHMANN, M., M. WEBER, J. M. ZÖLLNER, R. CIPOLLA y R. URTASUN (2016), «MultiNet: Real-time Joint Semantic Reasoning for Autonomous Driving», *CoRR*, **abs/1612.07695**, 1612.07695[cs.CV], URL <http://arxiv.org/abs/1612.07695>.
- [18] TODOROVA, K. y A. MANDINOVA (2020), «Novel approaches for managing aged skin and nonmelanoma skin cancer», *Adv. Drug Deliv. Rev.*, <https://doi.org/10.1016/j.addr.2020.06.004>.
- [19] WU, H., J. ZHANG, K. HUANG, K. LIANG y Y. YU (2019), «FastFCN: Rethinking dilated convolution in the backbone for semantic segmentation», *arXiv preprint arXiv: 1903.11816*[cs.CV].
- [20] YAKUBOVSKIY, P. (2020), «Segmentation Models Pytorch», https://github.com/qubvel/segmentation_models.pytorch.

-
- [21] ZHOU, J., B. HUANG, Z. YAN y J.-C. G. BÜNZLI (2019), «Emerging role of machine learning in light-matter interaction», *Light: Science & Applications*, **8**(1), págs. 1–7.

RESUMEN AUTOBIOGRÁFICO

Mario Alberto Flores Hernández

Candidato para obtener el grado de
Licenciatura en Ingeniería en Mecatrónica

Universidad Autónoma de Nuevo León
Facultad de Ingeniería Mecánica y Eléctrica

Tesis:

DETECCIÓN DE CANCER DE PIEL MEDIANTE SEGMENTACIÓN
SEMÁNTICA

Nací el 4 de junio de 1997 en la ciudad de Monterrey, Nuevo León. Hijo del Sr. Mario Alberto Flores Rosales y la Sra. Patricia Hernández Romero. Comencé mis estudios de Ingeniería En Mecatrónica en agosto de 2014 en la Universidad Autónoma de Nuevo León, en marzo de 2019 llevé a cabo el diplomado de Innovación Biomédica.